

Brain Tumor Classification Report

Robert-Iulian Balan

17 November 2024

Contents

1	Class Distribution	1
2	Data Visualization	3
2.1	Variabilitate Intraclasă	4
2.2	Similarități Interclasă	5
2.3	Caracteristici Distinctive	5
3	Dataset Analysis	5
4	Data Augmentation	6
5	Model Training	6
5.1	Training Configuration	6
5.2	Training Results	7
5.3	Model Evaluation	8

1 Class Distribution

The distribution of classes across the train, validation, and test splits shows notable patterns. In the train and validation sets, the `no_tumor` class is underrepresented, while the test split exhibits a more balanced distribution among classes.




Figure 1: Distribution of classes in the training dataset

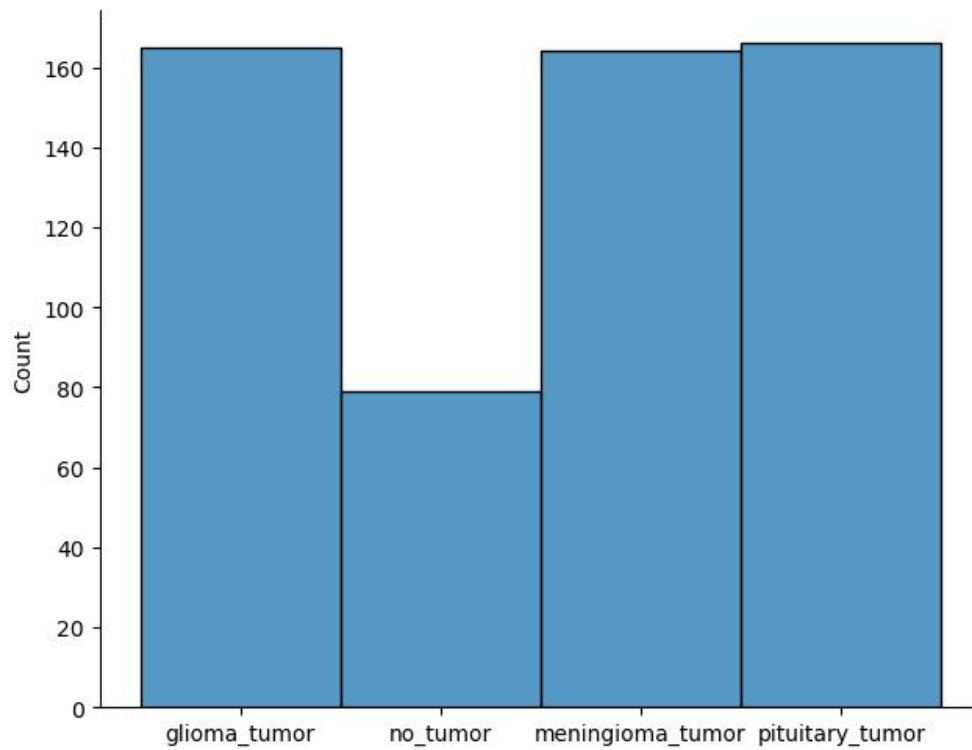


Figure 2: Distribution of classes in the validation dataset

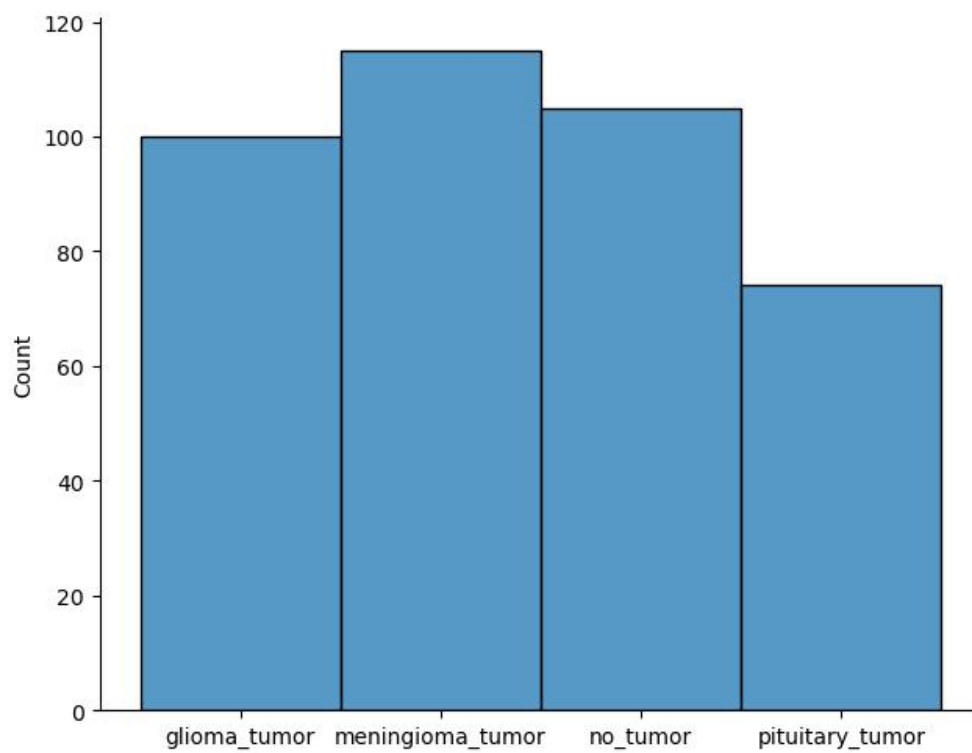


Figure 3: Distribution of classes in the test dataset

To address the class imbalance issue, we implemented random oversampling, which duplicates samples from the minority class. This technique successfully balanced the class distribution in the training set, as shown in Figure 4.

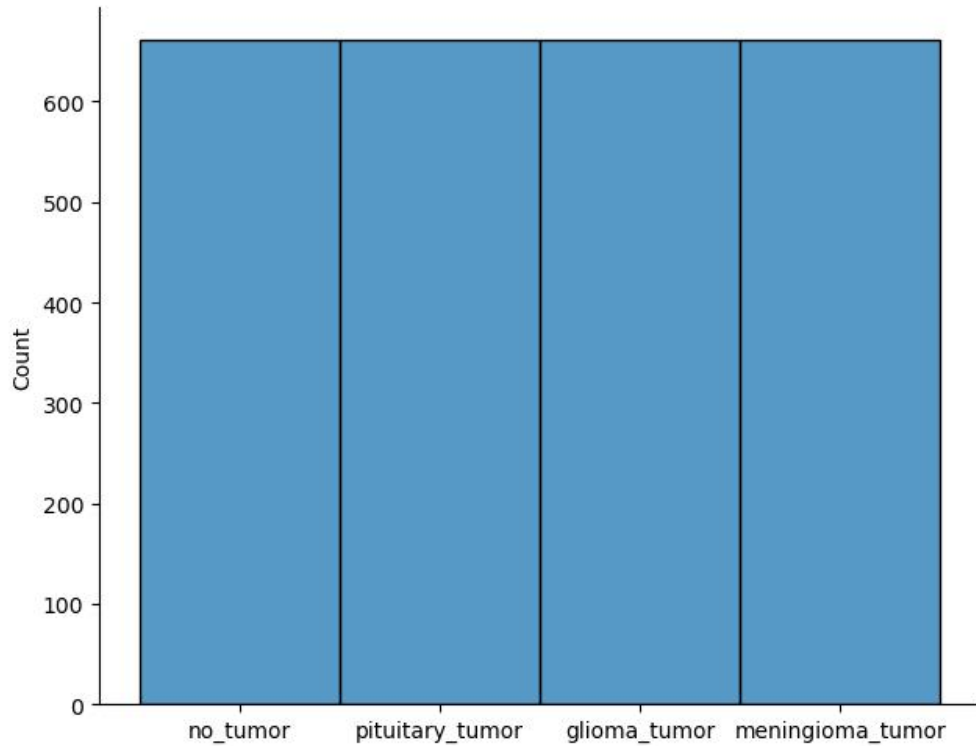


Figure 4: Class distribution after applying random oversampling to the training dataset

2 Data Visualization

Figure 5 shows representative samples from our dataset, illustrating the visual characteristics of different tumor classes.




Figure 5: Sample images from each class in the dataset

În urma analizei vizuale, am identificat următoarele caracteristici și provocări:

2.1 Variabilitate Intraclasses

- **Tumori Gliomice:** Prezintă o variabilitate semnificativă în forma și textura lor. Unele apar ca zone neregulate cu intensitate variabilă, în timp ce altele au margini mai bine definite. Textura poate varia de la omogenă la heterogenă, cu zone de intensitate diferită în interiorul aceleiași tumori.
- **Tumori Meningiomice:** Manifestă variații în dimensiune și formă, dar tind să aibă margini mai bine definite comparativ cu tumorile gliomice. Intensitatea lor poate varia de la moderată la ridicată.
- **Cazuri fără Tumori:** Prezintă variabilitate naturală în structura cerebrală, cu diferențe în contrast și distribuția țesuturilor normale.
- **Tumori Pituitare:** Având o localizare specifică în regiunea șei turcești, acestea prezintă variații în dimensiune și intensitate, dar tind să aibă o localizare mai consistentă comparativ cu alte tipuri de tumori.

2.2 Similarități Interclasă

- Există cazuri în care tumorile gliomice și meningiomice pot prezenta caracteristici vizuale similare, în special când au dimensiuni și localizări apropiate.
- Uneori, artefactele din imaginile fără tumori pot fi confundate cu leziuni tumorale mici.
- Zonele de edem din jurul tumorilor pot crea pattern-uri similare între diferitele tipuri de tumori.

2.3 Caracteristici Distinctive

- **Intensitate:** Tumorile meningiomice tind să apară mai luminoase în imagini, în timp ce tumorile gliomice pot prezenta zone de intensitate variabilă.
- **Localizare:** Tumorile pituitare au o localizare distinctă în regiunea șei turcești, în timp ce alte tipuri de tumori pot apărea în diverse zone ale creierului.
- **Pattern-uri de Contrast:** Diferențele în captarea contrastului între tipurile de tumori pot ajuta la diferențierea lor, cu meningioamele prezentând adesea o captare mai uniformă.
- **Efecte asupra Țesutului Înconjurător:** Tumorile gliomice tind să producă mai mult edem în țesutul înconjurător comparativ cu alte tipuri de tumori.

Aceste observații sugerează că, deși există caracteristici distinctive pentru fiecare clasă, variabilitatea intraclasă și similaritățile interclasă pot reprezenta provocări semnificative pentru modelul de clasificare. Acest lucru subliniază importanța unui set de date divers și reprezentativ, precum și necesitatea unor tehnici robuste de augmentare a datelor pentru a îmbunătăți performanța modelului.

3 Dataset Analysis

Our analysis of the dataset revealed several key characteristics:

- All images are in RGB format
- Image dimensions vary, with the majority (2,349 images) being 512×512 pixels
- A minority (1,263 images) have different dimensions
- To standardize the input, all images were resized to 227×227 pixels
- All images use 8-bit depth (uint8) with pixel values ranging from 0 to 255

4 Data Augmentation

We implemented the following data augmentation techniques to enhance model robustness:

1. **Vertical Flip:** Random vertical flipping with 0.5 probability
2. **Rotation:** Random rotation up to 45 degrees with 0.5 probability
3. **Gaussian Blur:** Applied to all images for noise reduction
4. **CLAHE** (Contrast Limited Adaptive Histogram Equalization): Enhanced image contrast
5. **Sobel Filter:** Edge detection and enhancement
6. **Normalization:** Centered distribution around 0




Figure 6: Examples of applied data augmentation techniques

5 Model Training

5.1 Training Configuration

We utilized the following configuration for model training:

- **Architecture:** AlexNet
- **Loss Function:** CrossEntropyLoss
- **Optimizer:** Stochastic gradient descent
- **Training Duration:** 90 epochs
- **Hyperparameters:**
 - Learning rate: 0.01
 - Momentum: 0.9
 - Weight decay: 0.0005
- **Learning Rate Scheduler:** 10-fold decrease with 10-epoch patience

5.2 Training Results

The training progression is visualized in Figure 7.




Figure 7: Training and validation metrics over epochs

5.3 Model Evaluation

The model achieved the following metrics on the test set:

- Test Accuracy: 73.24%
- F1 Score: 65.23%
- Precision: 65.23%
- Recall: 65.23%

Figure 8 shows the confusion matrix for the test set predictions.




Figure 8: Confusion matrix on test set